


Adaline



ADAPTATIVE LINEAR NEURON
(WIDROW 1960)

Desventajas del perceptrón




Adaline



- Al mismo tiempo que Rosenblatt trabajaba en el modelo del Perceptrón, **Widrow** introdujo el modelo de la red ADALINE y su regla de aprendizaje llamado algoritmo LMS (Least Mean Square). 1959.
- Características
 - Utiliza una función de transferencia lineal.
 - Resuelve problemas linealmente separables.
 - La regla LMS es superior al aprendizaje del Perceptrón ya que minimiza el error cuadrático medio.

Adaline – Asociador lineal



Asociador lineal



- Busca minimizar

$$\xi = \langle \varepsilon_k^2 \rangle = \langle (d_k - w^t x_k)^2 \rangle = 1/L \left[\sum_{k=1}^L (d_k - \sum_{i=0}^N x_{ik} w_i)^2 \right]$$

donde

L : Cantidad de Patrones

N : Cantidad de neuronas de entrada

< > representa promedio



d_k : salida esperada para el patrón x_k

Asociador lineal



- Entrenar un asociador lineal utilizando los siguientes patrones: $(-1,2)$, $(0,0)$, $(2,-4)$.
- La ecuación será de la forma
$$y = w_1 x$$

Note que y es la respuesta del asociador lineal.



Asociador lineal



- Se busca minimizar $\xi = \langle \varepsilon^2 \rangle = \frac{1}{L} \left[\sum_{k=1}^L \left(d_k - \sum_{i=0}^N x_{ik} w_i \right)^2 \right]$

$$\xi = \langle \varepsilon^2 \rangle = \frac{1}{3} \left((d_1 - w_1 x_1)^2 + (d_2 - w_1 x_2)^2 + (d_3 - w_1 x_3)^2 \right)$$

$$\xi = \frac{1}{3} \left((2 - w_1(-1))^2 + (0 - w_1 0)^2 + (-4 - w_1 2)^2 \right)$$


$$\xi = \frac{1}{3} \left((2 + w_1)^2 + (-4 - 2w_1)^2 \right)$$

$$\xi = \frac{1}{3} \left(4 + 4w_1 + w_1^2 + 16 + 16w_1 + 4w_1^2 \right) = \frac{1}{3} (20 + 20w_1 + 5w_1^2)$$

Asociador lineal



$$\xi = \frac{1}{3}(20 + 20w_1 + 5w_1^2)$$




- Derivando

$$\frac{\partial \xi}{\partial w_1} = \frac{1}{3}(20 + 10w_1) = 0 \Rightarrow w_1 = -2$$

- Respuesta del asociador lineal

$$y = -2x$$



Asociador lineal



- Entrenar un asociador lineal utilizando los siguientes patrones: (2,3), (1,1), (-1,-3).



- La respuesta del asociador lineal será de la forma:

$$y = w_1 x + w_0$$

- Se busca minimizar:

$$\xi = \frac{1}{3} \sum_{i=1}^3 \left(d_i - \sum_{j=0}^1 w_j x_{ij} \right)^2 = \frac{1}{3} \sum_{i=1}^3 \left(d_i - (w_1 x_i + w_o) \right)^2$$

Asociador lineal



- Se busca minimizar

$$\xi = \frac{1}{3} \sum_{i=1}^3 \left(d_i - \sum_{j=0}^1 w_j x_{ij} \right)^2 = \frac{1}{3} \sum_{i=1}^3 \left(d_i - (w_1 x_i + w_o) \right)^2$$

$$\xi = \frac{1}{3} \left((3 - (w_1 \cdot 2 + w_o))^2 + (1 - (w_1 + w_o))^2 + (-3 - (w_1 \cdot (-1) + w_o))^2 \right)$$

$$\xi = \frac{1}{3} \left((3 - 2w_1 - w_o)^2 + (1 - w_1 - w_o)^2 + (-3 + w_1 - w_o)^2 \right)$$

Asociador lineal



$$\xi = \frac{1}{3} \left((3 - 2w_1 - w_0)^2 + (1 - w_1 - w_0)^2 + (-3 + w_1 - w_0)^2 \right)$$

$$\frac{\partial \xi}{\partial w_1} = \frac{2}{3} \left((-2)(3 - 2w_1 - w_0) + (-1)(1 - w_1 - w_0) + (-3 + w_1 - w_0) \right)$$

$$\frac{\partial \xi}{\partial w_1} = \frac{2}{3} \left(-6 + 4w_1 + 2w_0 - 1 + w_1 + w_0 - 3 + w_1 - w_0 \right)$$

$$\frac{\partial \xi}{\partial w_1} = \frac{2}{3} \left(-10 + 6w_1 + 2w_0 \right) = 0 \quad \therefore \quad 3w_1 + w_0 - 5 = 0$$

Asociador lineal



$$\xi = \frac{1}{3} \left((3 - 2w_1 - w_0)^2 + (1 - w_1 - w_0)^2 + (-3 + w_1 - w_0)^2 \right)$$

$$\frac{\partial \xi}{\partial w_0} = \frac{2}{3} \left((-1)(3 - 2w_1 - w_0) + (-1)(1 - w_1 - w_0) + (-1)(-3 + w_1 - w_0) \right)$$

$$\frac{\partial \xi}{\partial w_0} = \frac{2}{3} (-3 + 2w_1 + w_0 - 1 + w_1 + w_0 + 3 - w_1 + w_0)$$

$$\frac{\partial \xi}{\partial w_0} = \frac{2}{3} (-1 + 2w_1 + 3w_0) = 0 \quad \therefore \quad 2w_1 + 3w_0 - 1 = 0$$

Asociador lineal



Sólo resta resolver el sistema de ecuaciones

$$\begin{cases} 3w_1 + w_0 - 5 = 0 & \Rightarrow w_0 = -3w_1 + 5 \quad (1) \\ 2w_1 + 3w_0 - 1 = 0 & (2) \end{cases}$$

Reemplazando (1) en (2)

$$2w_1 - 9w_1 + 15 - 1 = 0 \Rightarrow 14 - 7w_1 = 0 \Rightarrow w_1 = 2$$


De (1) $w_0 = -1$

La salida del Asociador Lineal será: $y = 2x - 1$

Asociador lineal





El asociador lineal a utilizar es el siguiente



Superficie de error

La gráfica del error que minimizamos es la siguiente

$$\xi = \frac{1}{3} \left((3 - 2w_1 - w_0)^2 + (1 - w_1 - w_0)^2 + (-3 + w_1 - w_0)^2 \right)$$




Mínimo en $w_0 = -1$, $w_1 = 2$

Entrenamiento del Asociador Lineal





- Se busca un método de entrenamiento que, a partir de los datos de entrada, permita calcular el vector W .

Concepto de
Gradiente



Gradiente



En esta imagen, el campo escalar se aprecia en blanco y negro, los cuales representan valores bajos o altos respectivamente, y el gradiente correspondiente se aprecia por flechas azules.

Minimización de funciones usando el gradiente



- Dada una función continua
 - Tomar un punto dentro del dominio de la función.
 - Calcular el vector gradiente de la función en ese punto.
 - Sumarle al punto anterior una fracción del gradiente negativo (para ir hacia el mínimo).
 - Repetir los dos pasos anteriores hasta que la diferencia entre evaluaciones consecutivas de la función sea inferior a una cierta cota.


Técnica del descenso del gradiente



$$w(t+1) = w(t) - \alpha \nabla \varepsilon_k^2(t)$$

- veamos que

$$\nabla \varepsilon_k^2(t) = -2\varepsilon_k(t)x_k$$



Técnica del gradiente



$$\nabla \varepsilon_k^2(t) = \frac{\partial \varepsilon_k^2}{\partial \mathbf{w}} = \left[\frac{\partial (d_k - y_k)^2}{\partial w_0}; \quad \dots; \quad \frac{\partial (d_k - y_k)^2}{\partial w_n} \right]$$

$$\nabla \varepsilon_k^2(t) = \frac{\partial \varepsilon_k^2}{\partial \mathbf{w}} = \left[-2(d_k - y_k) \frac{\partial y_k}{\partial w_0}; \quad \dots; \quad -2(d_k - y_k) \frac{\partial y_k}{\partial w_n} \right]$$

$$\nabla \varepsilon_k^2(t) = \frac{\partial \varepsilon_k^2}{\partial \mathbf{w}} = -2e_k \left[\frac{\partial y_k}{\partial w_0}; \quad \dots; \quad \frac{\partial y_k}{\partial w_n} \right]$$

$$\nabla \varepsilon_k^2(t) = \frac{\partial \varepsilon_k^2}{\partial \mathbf{w}} = -2e_k [x_{0k}, \quad x_{1k}, \quad \dots, \quad x_{nk}] = -2e_k \mathbf{x}_k$$

Algoritmo iterativo de entrenamiento del Adaline



- Para cada vector de entrada
 - Aplicar el vector de entrada x_k
 - Calcular el gradiente utilizando



$$\nabla \langle \varepsilon_k^2 \rangle \approx \nabla \varepsilon_k^2(t) = -2\varepsilon_k(t)x_k = -2(d_k - y_k)x_k$$

- Actualizar el vector de pesos

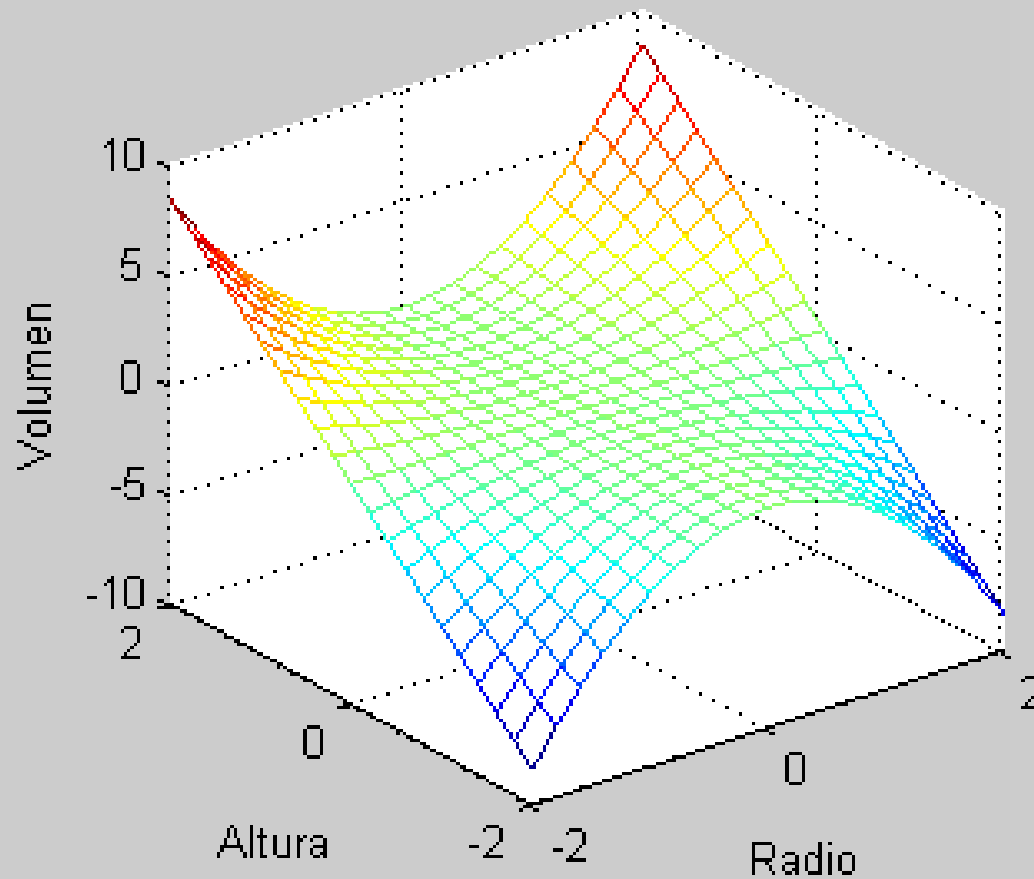
$$w(t+1) = w(t) + 2\alpha(d_k - y_k)x_k$$

- Repetir todo hasta que el error sea aceptable

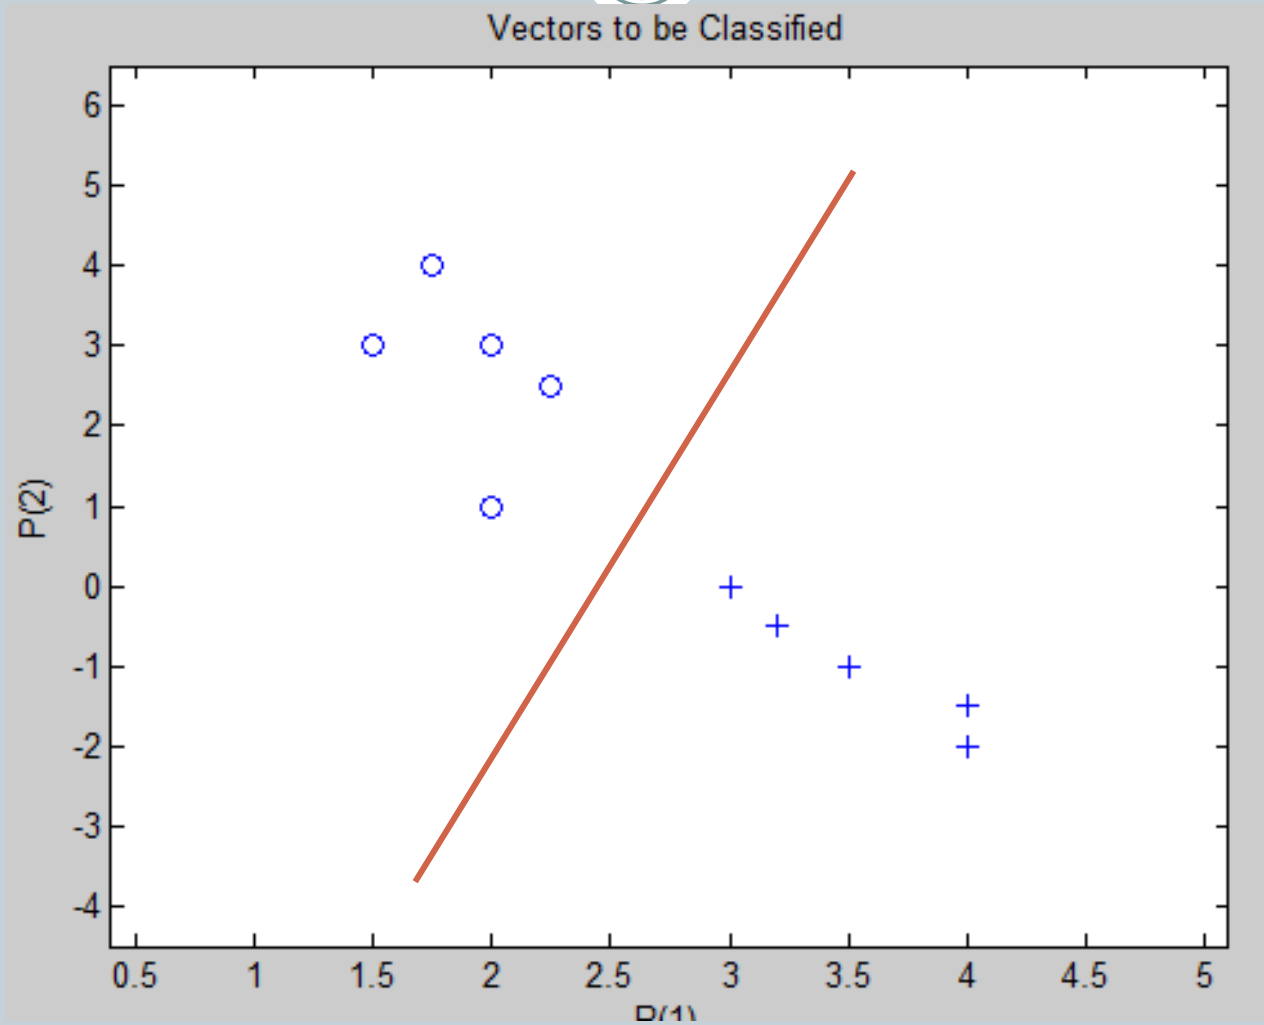
Minimización de funciones usando el gradiente



Minimización de funciones usando el gradiente




Combinador lineal



Combinador lineal





Vectors to be Classified




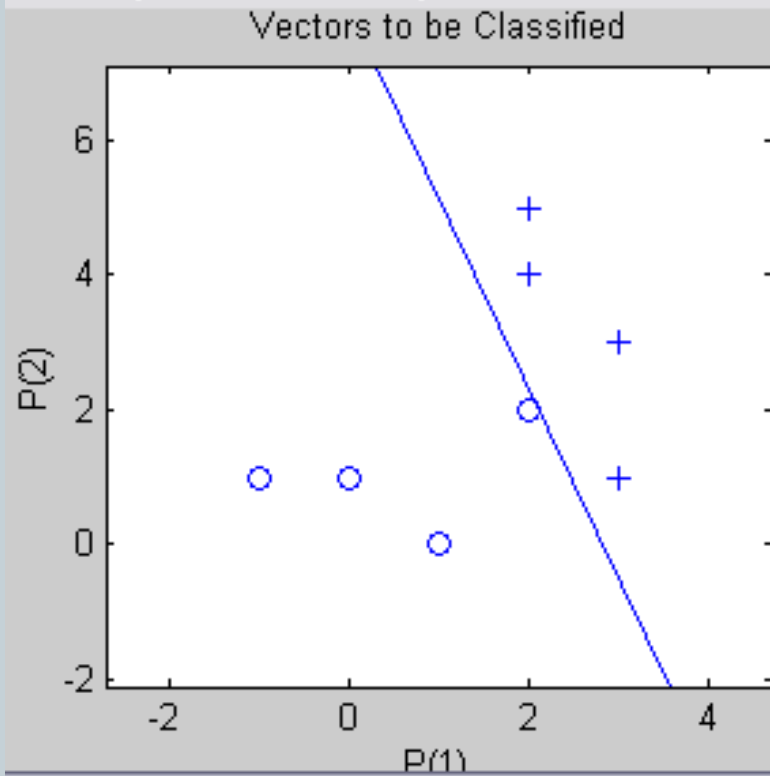
Combinador lineal



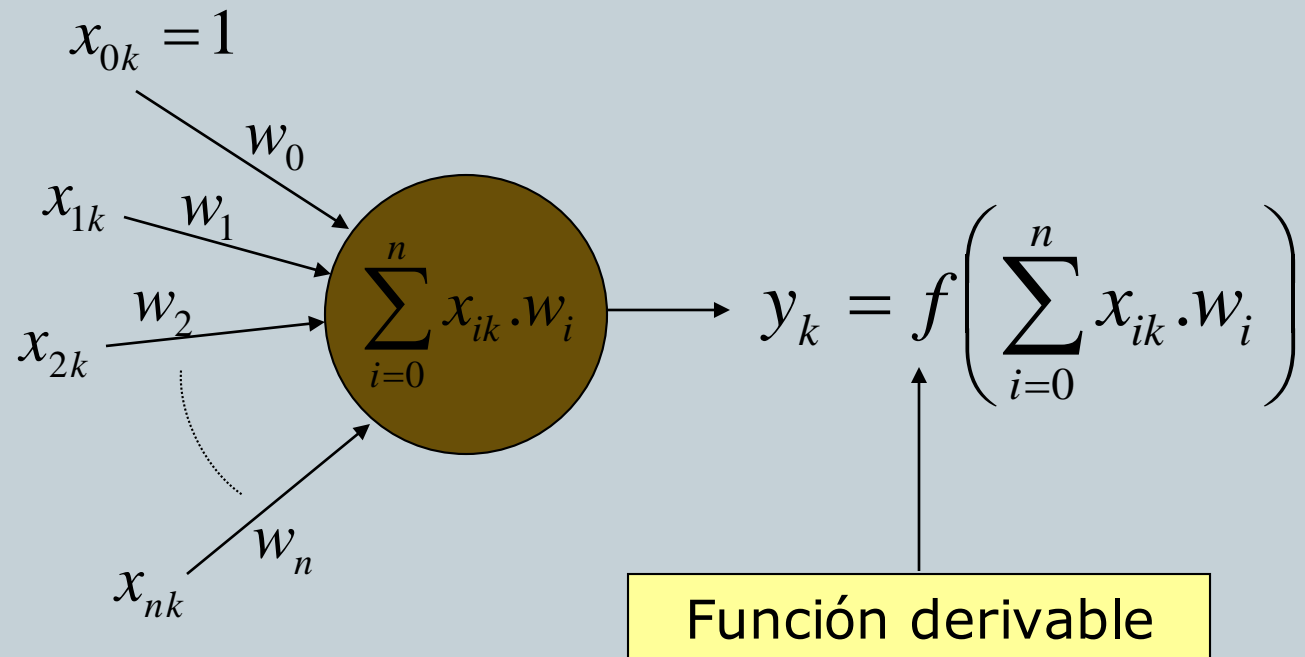
- Se agrega una nueva dimensión



Combinador lineal



Neurona general



¿Cómo sería la derivada del error si la neurona no es lineal?



$$\nabla \varepsilon_k^2 = \frac{\partial \varepsilon_k^2}{\partial \mathbf{w}} = \left[\frac{\partial (d_k - y_k)^2}{\partial w_0}; \quad \dots; \quad \frac{\partial (d_k - y_k)^2}{\partial w_n} \right]$$

$$\frac{\partial \varepsilon_k^2}{\partial w_j} = -2(d_k - y_k) \frac{\partial f_k}{\partial (neta_k)} \frac{\partial (neta_k)}{\partial w_j}$$

f_k'

$$\frac{\partial (neta_k)}{\partial w_j} = \frac{\partial (\sum_{j=0}^L w_j x_j)}{\partial w_j} = x_j$$

$$\frac{\partial \varepsilon_k^2}{\partial w_j} = -2(d_k - y_k) f_k'(neta_k) x_j$$

Método iterativo



- Para cada vector de entrada
 - Aplicar el vector de entrada, x_k
 - Calcular el gradiente utilizando

$$\nabla < \varepsilon_k^2 > \approx \nabla \varepsilon_k^2(t) = -2\varepsilon_k(t) f'_k(neta_k) x_k$$

- Actualizar el vector de pesos

$$w(t+1) = w(t) + 2\alpha \varepsilon_k f'_k(neta_k) x_k$$

- Repetir todo hasta que el error sea aceptable


Función de Salida LINEAL



- purelin

$$f(x) = x$$

$$f'(x) = 1$$

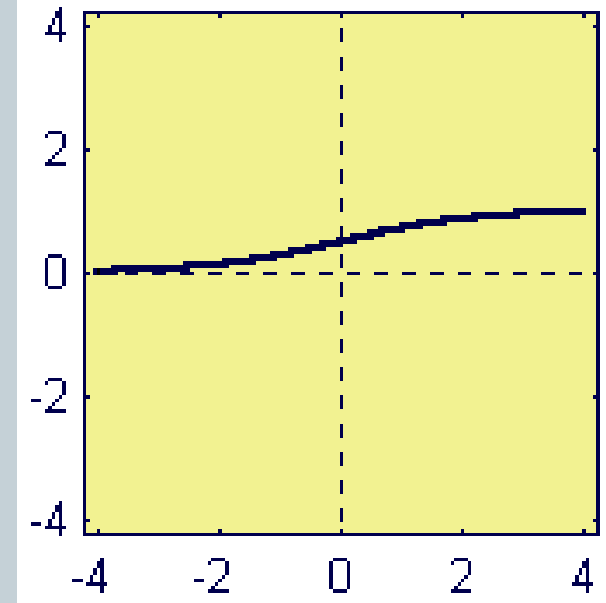


Función SIGMOIDE $\in (0,1)$



- logsig

$$f(x) = \frac{1}{1 + e^{-x}}$$



$$f'(x) = f(x) * (1 - f(x))$$


Función SIGMOIDE $\in (-1,1)$



- tansig

$$f(x) = \frac{2}{1 + e^{-2x}} - 1$$

$$f'(x) = 1 - f(x)^2$$



Adaline



- Bernard Widrow explicando el funcionamiento de su Adaline
- <https://youtu.be/hc2Zj55j1zU>
- <https://youtu.be/skfNlwEbqck>